PENERAPAN NATURAL LANGUAGE PROCESSING DAN NAMED ENTITY RECOGNITION DALAM PEMBUATAN TEKS OTOMATIS

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Mendapatkan

Gelar Sarjana Komputer (S.Kom) Program Studi Informatika

NURFADILAH RAHMAN

105841110421

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH MAKASSAR

2026

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Allah SWT atas limpahan rahmat, karunia, serta hidayah-Nya sehingga penulis dapat menyelesaikan penulisan skripsi ini yang berjudul **"Penerapan Natural Language Processing dan Named Entity Recognition dalam Pembuatan Teks Otomatis"**. Shalawat dan salam kepada Rasulullah Shalallahu 'Alaihi Wasallam yang senantiasa menjadi sumber inspirasi dan teladan terbaik untuk umat manusia. Tak lupa pula penulis menyampaikan rasa terima kasih yang setulusnya kepada kedua orang tua tercinta yang senantiasa memberikan doa, kasih sayang, dukungan, dan motivasi yang tiada hentinya.

Pada kesempatan ini dengan segala kerendahan hati, penulis ingin mengucapkan terima kasih sebesar-besarnya kepada semua pihak yang telah banyak membantu dalam penulisan skripsi ini, terutama kepada:

1. Bapak Dr. Ir. H. Abd. Rakhim Nanda, S.T.,M.T., IPU, selaku Rektor Universitas Muhammadiyah Makassar.
2. Bapak Ir. Muhammad Syafaat S Kuba, ST., MT, selaku Dekan Fakultas Teknik Universitas Muhammadiyah Makassar.
3. Ibu Rizki Yusliana Bakti, S.T.,M.T, selaku Ketua Program Studi Informatika Fakultas Teknik Universitas Muhammadiyah Makassar.
4. Ibu Ir. Ida, S.Kom.,M.T, selaku Dosen Pembimbing 1 yang telah memberikan arahan dan bimbingan serta saran yang sangat berarti dalam penulisan skripsi ini.
5. Ibu Darniati, S.Kom.,M.T, selaku Dosen Pembimbing 2 yang telah memberik an arahan dan bimbingan serta saran yang sangat berarti dalam penulisan skripsi ini.
6. Seluruh Dosen Program Studi Informatika Fakultas Teknik Universitas Muhammadiyah Makassar yang telah memberikan ilmu serta dorongannya dalam penulisan skripsi ini.
7. Teman-teman khususnya angkatan 2021 Program Studi Informatika Fakultas Teknik Universitas Muhammadiyah Makassar.

8. Kepada semua pihak yang sudah membantu, Penulis mengucapkan banyak terima kasih yang sebesar-besarnya.

Penulis menyadari bahwa dalam penulisan skripsi ini masih terdapat kekurangan untuk itu penulis mengharapkan kritik dan saran. Akhir kata, penulis berharap semoga skripsi ini dapat bermanfaat bagi semua pihak demi perkembangan dan kemajuan akademik.

Makassar, 26 Agustus 2025

Penulis,

Nurfadilah Rahman

DAFTAR ISI

KATA PENGANTAR ii

DAFTAR ISI iv

DAFTAR TABEL v

DAFTAR GAMBAR vi

BAB I PENDAHULUAN 1

A. Latar Belakang 1

B. Rumusan Masalah 3

C. Tujuan Penelitian 4

D. Manfaat Penelitian 4

E. Ruang Lingkup Penelitian 4

F. Sistematika Penulisan 5

BAB II TINJAUAN PUSTAKA 6

A. Landasan Teori 6

B. Penelitian Terkait 9

C. Kerangka Pikir 13

BAB III METODE PENELITIAN 14

A. Tempat dan Waktu Penelitian 14

B. Alat dan Bahan 15

C. Perancangan Sistem 15

D. Teknik Pengujian Sistem 17

E. Teknik Analisis Data 17

BAB IV HASIL DAN PEMBAHASAN

DAFTAR PUSTAKA 20

DAFTAR TABEL

Tabel 1. Perbedaan Penelitian Sebelum dan Terkini..... 11

Tabel 2. Waktu Penelitian ..... ……. 14

DAFTAR GAMBAR

Gambar 1. Kerangka Pikir 13

Gambar 2. Flowchart Perancangan Desain Sistem 15

BAB I
PENDAHULUAN

A. Latar Belakang

Di era perkembangan teknologi informasi dan komunikasi yang semakin pesat, data berbasis teks telah menjadi salah satu bentuk representasi informasi yang paling besar. Penggunaan teks sebagai media komunikasi tertulis terus meningkat seiring dengan digitalisasi berbagai askep kehidupan, mulai dari pendidikan, administrasi pemerintahan, jurnalistik, hingga layanan pelanggan dan interaksi media social. Setiap harinya, teks dalam jumlah besar dibuat dan disebarkan melalui berbagai platform digital, yang secara tidak langsung membutu hkan pengelolaan informasi yang efisien (Suhartono et al., 2024). Keadaan inilah yang menjadi dasar munculnya kebutuhkan akan suatu sistem yang mampu menghasilkan teks secara otomatis dan kontekstual untuk mendukung produkitivitas dan efisiensi kerja dalam berbagai bidang

Pembuataan teks otomatis atau *automated text generation* merupakan salah satu solusi berbasis kecerdasan buatan yang memberikan pendekatan melalui Natural Language Processing dan Named Entity Recognition (Islamey et al., 2024). Sistem ini mampu menghasilkan teks secara mandiri berdasarkan data atau masukan tertentu, seperti deksripsi, ringkasan, ataupun dokumen. Teknologi ini dinilail mampu mendukung efisiensi waktu, mengurangi beban kerja administratif, serta mempertahankan kemiripan gaya dan struktur penulisan (Muftie & Haris, 2023). Sistem generatif berbasis teks tidak hanya dapat menyusun kalimat yang sistematis tetapi juga mampu menyesuaikan gaya dan konteks bahasa pengguna, sehingga sangat bermanfaat untuk sektor pendidikan dan manajemen konten digital (Ahmadian et al., 2024).

Untuk menghasilkan sebuah teks yang akurat, relevan, dan kontekstual dibutuhkan pendekatan linguistik komputasional, yaitu dokumen naratif lainnya *Natural Language Processing (*NLP) (Sebastian et al., 2022). NLP merupakan cabang dari kecerdasan buatan yang berfokus pada pemrosesan dan pemahaman bahasa manusia oleh sisten komputer. Salah satu teknik penting dalam NLP adalah *Named Entity Recognition* (NER), yakni proses untuk mengenali dan

mengklasifikasikan entitas-entitas bernama dalam teks seperti nama orang, institusi, lokasi, dan waktu. Penggabungan NER dalam sistem generatif memungkinkan pengenalan unsur penting dan menghasilkan teks yang lebih informatif dan spesifik. Penggunaan pendekatan NER berbasis konteks dapat menignkatkan performa sistem dalam menangkap informasi entitas yang kompleks secara signifikan (Ahmadian et al., 2024).

Pembuatan teks otomatis umumnya melibatkan dua proses utama, yaitu tahap pemahaman teks (*text understanding)* dan tahap (*text generation).* Pada proses pemahaman, sistem perlu mengestrak informasi penting dari teks sumber, seperti entitas, kata kunci, dan hubungan antar kata. Salah satu model yang banyak digunakan dalam tahap ini adalah IndoBERT, sebuah *pre-trained* model yang dioptimalkan untuk Bahasa Indonesia dan terbukti efektif dalam tugas pemahaman teks seperti klasifikasi. Selain itu, library spaCy juga dimanfaatkan dalam tahap pra-pemrosesan, seperti tokenisasi, parsing. Namun, baik IndoBERT dan spaCy pada dasarnya lebih berfokus pada pemahaman teks, bukan sebagai pembuatan teks yang baru. Oleh karena itu, agar sistem benar-benar mampu menghasilkan teks otomatis, diperluakan tambahan model generative. Salah satu model yang relevan adalah IndoBART, yang merupakan turunan dari arsitektur BART yang menggabungkan kemampuan encoder untuk memahami decoder untuk menghasilkan sebuah teks. Model generasi ini tidak hanya efektif untuk pembuatan teks otomatis tetapi juga dapat digunakan dalam berbagai tugas lain, seperti summarization, translation, dan question answering

Namun dalam konteks Bahasa Indonesia masih tergolong sebagai bahasa dengan sumber daya yang terbatas*(low-resource language),* yang memiliki tantangan dalam hal ketersediaan makna beranotasi, dokumentasi linguistik, dan pengembangan model (Koto et al., 2020). Struktur sintaksis yang fleksibel serta kekayaan morfologis Bahasa Indonesia menuntut sistem yang tidak hanya bersifat generik, tetapi juga adaptif terhadap karakteristik kebahasaan lokal. Untuk itu, model *IndoBERT* yang merupakan adaptasi dari arsitektur BERT untuk Bahasa Indonesia dapat digunakan karena telah menunjukkan performa yang baik dalam klasifikasi token dan pengenalan entitas. Selain itu, pustaka NLP seperti *spaCy* mendukung implementasi pipeline pemrosesan bahasa secara modular, efisien dan

dapat dikombinasikan dengan model pembelajaran mesin lainnya untuk membentuk sistem yang terpadu (Yanti et al., 2021).

Kebutuhan akan teks otomatis ini dibutuhkan dalam pelayanan public. Berdasarkan data dari Kantor Lurah Tadokkong, jumlah pembuatan dokumen administratif seperti surat keterangan domisili, surat keterangan usaha, dan surat pengantar mencapai puluhan atau ratusan dokumen. Proses penyusunan dokumen ini masih dilakukan secara manual sehingga seringkali menyebabkan keterlambatan pelayanan dan ketidakkonsistenan format. Oleh karena itu, penerapan sistem pembuatan teks otomatis berbahasa Indonesia menjadi solusi untuk membantu pegawai dalam mempercepat, efisiensi, seta meningkatkan kualitas pelayanan administrasi masyarakat.

Berdasarkan permasalahan diatas, penelitian ini bertujuan untuk mengembangkan sistem pembuatan teks otomatis berbahasa indonesia dengan menggabungkan pendekatan *Natural Language Processing* dan *Named Entity Recognition* melalui pemanfaatan model *IndoBERT* dan pustaka *spaCy* sebagai komponen dan IndoBART sebagai generatif. Penelitian ini diharapkan dapat menghasilkan sistem yang mampu menyusun teks secara otomatis dengan tingkat akurasi tinggi, relevansi kontekstual yang kuat, dan keutuhan informsi yang terjaga. Selain kontribusi dalam bidang ilmu pengembangan linguistik, sistem ini juga diharapkan memberikan manfaat praktis bagi pendidik, pengembang konten, layanan publik, serta pembangku kebijakan yang membutuhkan solusi penulisan otomatis dalam bahasa indonesia

B. Rumusan Masalah

Berdasarkan latar belakang diatas, maka dapat rumuskan suatu rumusan yang menjadi penelian sebagai berikut:

1. Bagaimana merancang sistem pembuatan teks otomatis dalam bahasa indonesia yang mampu menghasilkan dokumen teks
2. Bagaimana penerapan *Natural Language Processing* (NLP) dan *Named Entity Recognition* (NER) dapat meningkatkan kualitas teks yang dihasilkan?
3. Bagaimana peningkatan akurasi NER berbasi IndoBERT dapat mendukung kualitas teks otomatis yang dihasilkan dari segi akurasi, relevansi, dan keutuhan informasi?

C. Tujuan Penelitian

Tujuan dari penelitian ini seperti::

1. Merancang dan mengembangkan sistem otomatisasi pembuatan dokumen teks berbahasa Indonesia
2. Menerapkan *Natural Language Processing* (NLP dan *Named Entity Recognition* (NER) berbasis IndoBERT dan pustaka pipeline spaCy untuk meningkatkan kualitas dalam memahami serta mengekstraksi informasi penting dari dokumen teks
3. Menganalisis peran NER berbasis IndoBERT terhadap kualitas teks otomatis yang dihasilkan, khususnya dalam aspek akurasi, relevan, serta keutuhan informasi yang dihasilkan.

D. Manfaat Penelitian

Adapun manfaat dari penelitian ini mencakup sebagai berikut:

1. Penelitian ini diharapkan dapat menjadi sarana pengembangan wawasan dan pemaham penulis dalam mengimplementasikan metode *Natural Language Processing* dan *Named Entity Recognition* dan pustaka spaCy, khususnya dalam konteks pengembangan sistem pembuatan teks otomatis.
2. Hasil penelitian ini diharapkan dapat memberikan kontribusi sebagai referensi ilmiah dalam bidang generasi teks otomatis dan pemrosesan bahasa alami
3. Sistem dikembangkan dalam penelitian ini diharapkan dapat dimanfatkan sebagai solusi praktis dalam berbagai kebutuhan berbasis teks, serta peningkatan efisiensi dalam penyampaian informasi diberbagai bidang seperti pendidikan, pemerintahan, dan pelayanan publik

E. Ruang Lingkup Penelitian

Adapun batasan dalam penelitian agar memilik fokus yang jelas dan pelaksanaan yang terarah, maka ruang lingkup ini ditetapkan sebagai berikut:

1. Penelitian difokuskan pada pengembangan sistem pembuatan teks otomatis menggunakan pendekatan NLP dan NER
2. Dataset dokumen surat administratif digunakan sebagai sumber referensi format dan struktur surat, sedangkan input utama sistem berupa entitas hasil ekstraksi seperti nama, NIK, alamat, pekerjaan, tanggal, jabatan, dan informasi

lain sesuai jenis surat

3. Evaluasi sistem dilakukan untuk mengukur akurasi, relevansi dan kemampua n dalam mengenali suatu entitas dan generatif teks

F. Sistematika Penulisan

Sistematika penulisan ini disusun sebagai gambaran umum tentang penelitian yang akan dilakukan. Sistematika penulisan ini sebagai berikut:

BAB I PENDAHULUAN

Bab ini menjelaskan tentang latar belakang, rumusan masalah, tujuan penelitian, manfaat penelitian, ruang lingkup penelitian serta sistematika penulisan pada penelitian yang dilakukan.

BAB II TINJAUAN PUSTAKA

Bab ini membahas tentang landasan teori, penelitian terkait, dan kerangka berpikir yang berfungsi sebagai panduan sistematis dalam memahami hubungan antara variabel yang diteliti.

BAB III METODE PENELITIAN

Bab ini menjelaskan tentang metode penelitian yang digunakan, meliputi pendekatan penelitian, cara pengumpulan data, serta langkah-langkah analisis yang digunakan dalam penelitian.

BAB II
TINJAUAN PUSTAKA

A. Landasan Teori

1. Pembuatan Teks Surat Otomatis

Pembuatan teks surat otomatis adalah proses yang menggunakan model kecerdasan buatan dan algortima untuk menghasilkan teks secara otomatis berdasarkan input. Dalam beberapa tahun terakhir, teknologi ini telah mengalami perkembangan besar sebagai hasil dari kemajuan dalam bidang pemrosesan bahasa natural. Pembuatan teks otomatis digunakan dalam berbagai sistem, seperti ringkasan otomatis, deskripsi produk, dan chatbot.

Dalam proses ini melibatkan beberapa tahapan yang saling berkaitan, mulai dari pengumpulan data, ekstraksi informasi, analisis bahasa untuk menghasilkan struktur kalimat yang konsisten. Selain itu, yang menjadi tantangan utama dalam proses ini tidak hanya memastikan teks yang dihasilkan akurat tetapi juga sesuai dengan konteks dan gaya bahasa yang diinginkan. Penggunaan model berbasis transformer dapat membantu meningkatkan performa sistem dengan akurasi yang tinggi dalam beberapa matrik evaluasi teks (Fardhina et al., 2025).

2. *Natural Language Processing* (NLP)

Natural Language Processing merupakan salah satu cabang dari kecerdasan buatan yang berfokus pada interaski antara komputer dan bahasa manusia. Tujuannya adalah untuk memungkinkan sistem memahami dan menghasilkan bahasa manusia secara efektif. NLP memiliki peran penting dalam berbagai aplikasi seperti chatbot, penerjemahan otomatis, dan sistem tanya jawab otomatis. Dalam konteks pembuatan teks otomatis, NLP menjadi fondasi utama karena memiliki mekanisme analisis dan manipulsai bahasa yang diperlukan(Fathoni, 2025).

NLP memiliki komponen dasar seperti tokenisasi (pemecahan teks menjadi kata), part-of-speech (POS) tagging (penandaan kelas kata benda, kerja, dll.), parsing sintaksis (analisis struktur kalimat), serta analisis semantik (pemahaman makna). Komponen inilah yang berkerja sama dalam membangun pemahaman terhadap struktur dan isi teks masukan sebelum proses generasi dilakukan

Peran NLP dalam sistem teks otomatis sangat krusial karena menjadi jembatan antara struktur linguistic dan bentuk representasi numerik yang dapat diproses oleh

mesing. Dengan menerapkan NLP secara tepat, sistem dapat menghasilkan kalimat yang tidak hanya gramatikal melainkan juga semantik dan kontekstual. Model deep learning berbasis Transformer seperti IndoBERT dapat digunakan dalam konteks bahasa Indonesia untuk menghasilkan akurasi yang akurat(Mahira Putri et al., 2023).

3. *Named Entity Recognition* (NER)

Named Entity Recogniton (NER) adalah teknik NLP yang bertujuan mengenali dan mengklasifikasi entitas seperti orang, organisasi, lokasi, serta entitas lainnya dari sebuah teks. (Hidayatullah et al., 2023) dalam penelitiannya mengembangkan model BiLSTM untuk mengenali entitas dalam ulasan destinasi wisawata berbahasa Indonesia, dengan performa F1-Score 94,3% pada dataset dengan anotasi entitas seperti tujuan wisata, lokasi, dan fasilitas. Penelitian ini menunjukkan bahwa metode sekuensial seperti BiLSTM masih efektif dalam domain khusus seperti pariwisata. Sementara itu (Subowo et al., 2025), memperkenalkan dataset dan model NER untuk dokumen keputusan pengadilan tindak korupsi di Indonesia, fokus pada entitas hukum seperti pasal, undang-undang, dan sanksi yang penting untuk mendukung transparansi dan akses informasi hukum. Dari penelitian tersebut ini menekankan kebutuhan akan dataset domain-spesifik untuk meningkatkan akurasi NER di ranah hokum

Sementara itu Theofany Aulia Anwar et al., (2024) menggabungkan metode TextRank dengan NER pada artikel berita daring untuk mengekstraksi kata kunci yang relevan secara lebih efektif, metode kombinasi ini menunjukkan peningkatan nilai *recall, precision, f-measure,* dan akurasi dibandingkan dengan menggunakan TextRank tunggal. Studi ini menunjukkan kemampuan NER tidak hanya untuk ekstraksi entitas semata, tetapi juga memperkuat kualitas ringkasan dan indeksasi informasi. Hasil tersebut relevan untuk pipeline pembuatan teks otomatis yang memerlukan ektraksi elemen penting sebelum pembentukan teks akhir.

4. IndoBERT dan IndoBART

IndoBERT merupakan adaptasi dari arsitektur BERT (*Bidirectional Encoder Represenation from Transformer*) yang secara khusus dilatih untuk Bahasa Indonesia. Sebagai model berbasis encoder, IndoBERT memiliki keunggulan dalam tugas-tugas pemahaman teks (*text understanding*) seperti klasifikasi kalimat,

analisis sentiment, dan terutama *Named Entity Recognition* (NER). Model ini memanfaatkan mekanisme selft-attention sehingga mampu menangkap hubungan antar kata secara kontekstual. Efektivitas IndoBERT dalam meningkatkan akurasi menunjukkan bahwa pemahaman teks berbahasa Indonesia memiliki akurasi yang lebih baik dibandingkan dengan model berbasis word embedding konvesional (Koto et al, 2020). Dengan demikian, IndoBERT dapat dimanfaatkan sebagai komponen penting dalam tahap ekstraksi informasi sebelum dilakukan pemrosesan teks otomatis

Sementara itu, IndoBART merupakan adaptasi dari arsitektur BART (Bidirectional and Auto-Regressive Transformers) untuk Bahasa Indonesia, yang menggabungkan kemampuan encoder seperti pada BERT dan decoder seperti pada GPT. Perbedaan utama IndoBART dengan IndoBERT adalah pada kemampuannya menghasilkan teks baru (text generation). Model ini telah digunakan secara luas dalam berbagai tugas generatif, seperti summarization, machine translation, question answering, hingga pembuatan teks otomatis. Karakteristik encoder–decoder memungkinkan IndoBART untuk tidak hanya memahami konteks dari teks sumber, tetapi juga membangkitkan keluaran baru yang koheren, relevan, dan menyerupai bahasa alami (Tohir et al., 2024). Dengan mengombinasikan IndoBERT pada tahap pemahaman teks dan IndoBART pada tahap generasi, sistem pembuatan teks otomatis berbahasa Indonesia dapat dibangun dengan lebih efektif, mengingat kedua model tersebut saling melengkapi dalam fungsi dan kinerjanya.

5. spaCy

spaCy adalah pustaka NLP open-source yang dirancang untuk efisiensi tinggi dan digunakan luas dalam pengembangan dengan menyediakan komponen-komponen penting seperti tokenisasi, POS-tagging, dependency parsing yang dapat ditingkatkan melalui pelatihan ulang. Selain itu spaCy diterapkan untuk klasifikasi berita berbahasa Indonesia berbasis ekstraksi entitas seperti orang, tempat, dan tanggal, dan memperoleh F1-score sebesar 89,69% hasil ini menunjukkan efektivitas spaCy dalam menangani teks informasai berskala besar dengan struktur linguistic yang beragam(Nurchim et al., 2023). Hal ini relevan karena model spaCy dapat digunakan sebagai komponen ekstraksi entitas dalam pipeline pembuatan teks otomatis.

Sementara itu, pustaka pipeline spaCy menunjukkan hasil yang unggul dalam metrik F1-score, akurasi, serta waktu efisiensi dibandingkan pustaka lain. Keunggulan inilah yang menjadikan pipeline spaCy menjadi pilihan utama untuk pemrosesan dara teks dalam jumlah yang besar, seperti pada sistem pembuatan teks otomatis yang memerlukan respon cepat dan efisiensi tinggi. Selain itu, meskipun model pralatih bawaan berfokus pada bahasa berdaya sumber besar, spaCy masih relevan untuk disesuaikan dengan Bahasa Indonesia karena fleksibilitasnya dalam *fine-tune* model untuk domain tertentu (Akhtar et al., 2024). Hal ini menguatkan bahwa spaCy sebagai komponen penting dalam integrase sistem NER untuk menghasilkan teks otomatis yang kontekstual dan berkualitas.

B. Penelitian Terkait

Berikut beberapa penelitian sebelumnya yang terkait meliputi:

1. Peringkasan Teks Otomatis Abstraktif Menggunakan Transformer Pada Teks Bahasa Indonesia (Bahari & Dewi, 2024)

   Penelitian ini menggunakan arsitektur Transformer untuk membuat peringkasan teks otomatis, khususnya arsitektur T5 pada teks berita berbahasa Indonesia. Model ini dilatih dengan dataset Indosum dan menghasilkan ringkasan yang lebih natual dengan skor evaluasi ROUGE-1 sebesar 0,61 dan ROUGE-2 dengan hasil 0,51. Hasil ini menunjukkan bahwa pendekatan abstraktif berbasis deep learning cukup efektif dalam menghasilkan ringkasan yang mendekati bahasa Indonesia. Dengan hasil akurasi yang tinggi ini dapat disimpulkan bahwa penggunaan Transformer masih efektif.

2. Pembangkitan interpretasi tekstual berbahasa Indonesia berdasarkan data pemeriksaan kimia darah menggunakan pendekatan berbasis r-template (Aulia et al., 2020)

   Penelitian ini menerapkan metode r-template dalam pembuatan teks interpretatif secara otomatis pada hasil uji laboratorium kimia darah. Sistem yang dikembangkan mampu menghasilkan narasi medis sederhana dengan tingkat keterbacaan sebesar 70% dan relevansi 60%. Meskipun berbasis *rules*, hasil penelitian ini menunjukkan bahwa pembuatan teks otomatis dapat diterapkan pada domain spesifik dengan hasil yang cukup meyakinkan.

3. Enhancing Question Generation in Bahasa Using Pretrained Language Models

(Fredyan et al., 2024)

Penelitian ini menerapkan sejumlah model termasuk IndoBART, IndoBERT, IndoGPT dalam pembuatan pertanyaan otomatis (*automatic question generation*). Selain itu evaluasi juga dilakukann dengan menggunakan metrik BLEU dengan skor berkisar antara 0,21-0,28 dan ROUGE-L yang mencapai 0,36. Hal ini menunjukkan bahwa model berbasis *transformer* mampu memberikan hasil teks otomatis dengan kualitas yang mumpuni.

4. Peringkasan Teks Otomatis menggunakan Metode Latent Semantic Analysis pada Artikel Berita Ekonommi berbahasa Indonesia (Sianturi et al., 2023)

   Penelitian ini menggunakan metode LSA untuk melakukan peringkasan teks otomati pada artikel berita ekonomi. Hasil pengujian pada kompresi 10% menunjukkan nilai precision 0,7917, recall 0.1481, f-measure 0,2427, dan akurasi sebesar 0,9015. Namun, Ketika kompresi ditingkatkan hingga 30%, akurasinya menjadi menurun dengan nilai 0,7874. Hal ini menunjukkan bahwa kualitas ringkasan sangat bergantung pada tingkat kompresi yang ditetapkan.

5. Peringkas Teks Otomatis Artikel Berbahasa Indonesia Menggunakan Algoritma TextRank (Husniah et al., 2022)

   Penelitian ini mengaplikasikan algortima TextRank dalam melakukan peringkasan artikel online. Dengan tingkat kompresi 50% sistem mampu menghasilkan skor ROUGE-1 sebesar 68,76%, ROUGE-2 60,60%, dan ROUGE-L sebesar 68,29%. Hasil ini menunjukkan bahwa metode TextRank mampu memberikan ringkasan yang relevan.

6. Penerapan NLP dalam Analisis Sentimen Pengguna Telegram di Playstore (Suarna & Prihartono, 2024)

   Penelitian ini menggunakan NLP dengan algoritma Naïve Bayes untuk analisis sentiment ulasan pengguna Telegram di Playstore. Hasilnya menunjukkan akurasi 85,31% dengan F1-score 88%. Penelitian ini memperlihatkan penerapan NLP dalam mengolah teks bahasa Indonesia pda domain media social.

7. Penerapan NER Pada Artikel Berita Online Tentang Kriminalitas Menggunakan IndoBERT (Hakim, 2023)

   Penelitian ini menerapkan IndoBERT untuk melakukan NER pada berita kriminalitas online. Hasil evaluasi menunjukkan recall sebesar 0,9017, precission

0,8884, dan F1-Score 0,8950. Studi ini menegaskan bahwa efektivitas IndoBERT dalam ekstraksi entitas di teks kriminalitas

Tabel 1. Perbedaan Penelitian Penulis dengan Penelitian Sebelumnya

No.	PENELITIAN SEBELUMNYA	PENELITIAN TERKINI
1	Peringkasan Teks Otomatis Abstraktif Menggunakan Transformer Pada Teks Bahasa Indonesia (Bahari & Dewi, 2024). Penelitian ini berfokus pada peringkasan teks dengan arsitekktur T5	Sedangkan penelitian terkini fokus pada pembuatan teks otomatis berbahasa Indonesia menggunakan kombinasi NLP dan NER (IndoBERT, spaCy) serta model generative IndoBART.
2	Pembangkitan interpretasi tekstual berbahasa Indonesia berdasarkan data pemeriksaan kimia darah menggunakan pendekatan berbasis r-template (Aulia et al., 2020). Penelitian menggunaakan pendekatan rule-based pada domain khusus medis	Sedangkan penelitian ini menggunakan pendekatan deep learning berbasis transformer (IndoBERT dan IndoBART)
3	Enhancing Question Generation in Bahasa Using Pretrained Language Models (Fredyan et al., 2024). Dari penelitian ini menggunakan model IndoBERT, IndoBART, dan IndoGPT dalam membuat pertanyaan otomatis.	Penelitian ini berfokus pada pembuatan teks naratif otomatis secara umum, bukan hanya pertanyaaan
4	Peringkasan Teks Otomatis menggunakan Metode Latent Semantic Analysis pada Artikel Berita Ekonommi berbahasa Indonesia (Sianturi et al., 2023). Penelitian ini menggunakan metode Latent Semantic Analysis untuk membuat ringkasan teks	Sedangkan penelitian terkini berfokus pada pendekatan transformer modern dengan model IndoBERT dan IndoBART yang lebih kontekstual dan relevan
5	Peringkas Teks Otomatis Artikel Berbahasa Indonesia Menggunakan Algoritma TextRank (Husniah et al., 2022). Penelitian ini berfokus	Penelitian ini fokus pada generasi teks otomatis dengan memanfaatkan NLP, NER, dan

	pada ringkasan teks berbasis graph	model generative.
6	Penerapan NLP dalam Analisis Sentimen Pengguna Telegram di Playstore (Suarna & Prihartono, 2024). Penelitian ini menggunakan NLP dengan algoritma Naïve Baiyes untuk analisis sentiment teks.	Penelitian ini berfokus pada NLP dan NER dengan pendekatan Transformer, serta pembuatan teks otomatis, bukan hanya analisis sentiment.
7	Penerapan NER Pada Artikel Berita Online Tentang Kriminalitas Menggunakan IndoBERT (Hakim, 2023). Penelitian ini memanfaatkan IndoBERT untuk pengenalan entitas dalam berita kriminalitas	Pnelitian ini juga memanfaatkan IndoBERT, namun fokusnya bukan hanya pada NER, melainkan interasi NLP, NER, dan model generative IndoBART untuk menghasilkan teks otomatis.

C. Kerangka Berpikir

Masalah
Permasalahan utama yang dihadapi adalah adanya keterbatasan dalam pengelolaan data hingga terkadang pelayanan publik menjadi kurang efektif. Kondisi ini ditunjukkan dengan pembuatan dokumen masih dibuat secara manual.

Solusi
Penerapan pendeketan NLP, NER dan sistem generatif untuk menghasilkan sebuah teks yang informatif dan akurat

Hasil
Menghasilkan sebuah sistem pembuatan teks otomatis yang informatif, konteksutal dan relevan yang dapat digunakan dengan menggunakan metode gabungan NLP dan NER

Gambar 1. Diagram Kerangka Pikir

BAB III
METODE PENELITIAN

A. Tempat dan Waktu Penelitian

1. Tempat Penelitian

   Penelitian ini dilakukan di Kantor Kelurahan Tadokkong, Kec. Lembang yang beralamat di Tuppu, Kel. Tadokkong, Kec. Lembang, Kab. Pinrang, Sulawesi Selatan 91254.

B. Alat dan Bahan

1. Hardware (Perangkat Keras) yang digunakan
   a. Laptop Acer Aspire 3
      - Processor AMD Athlon Silver 3050U
      - RAM 8
2. Software (Perangkat Lunak) yang digunakan
   a. Visual Studio Code
   b. Python 3.x sebagai bahasa pemrograman utama
   c. Library NLP

C. Perancangan Sistem

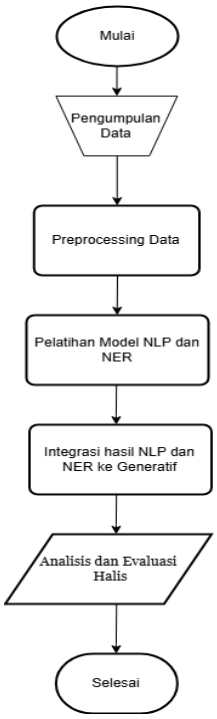

Gambar 3. Flowchart Perancangan Sistem

1. Pengumpulan Data

   Tahap awal mengumpulkan dokumen teks surat berbahasa indonesia yang diambil dari teks dokumen administrasi. Dataset ini akan dijadikan sebagai template

2. Pra-pemrosesam Data

   Dataset yang didapatkan selanjutnya akan melalui pra-pemrosesan. Pada tahap ini dilakukan pembersihan data, tokenisasi, nomalisasi kata. Selain itu data dibagi menjadi dua bagian, yaitu data training dan data testing

3. Pelatihan Model NLP

   Setelah data siap, tahap berikutnya adalah pelatihan model NLP menggunakan IndoBERT. Model ini digunakan untuk memahami struktur dan makna teks melalui proses representasi kontekstual sehingga sistem mampu mengenali pola dalam bahasa yang digunakan.

4. Pelatihan Model NER

   Pada tahap ini diterapkan metode NER menggunakan pipeline spaCy. Tujuannya untuk mengenali serta mengklasifikasikan entitas penting dalam teks seperti nama, tanggal, jabatan dan sebagainya. Hasil dari tahap ini berupa data yang lebih kaya dan informatif

5. Integrasi hasil NLP dan NER ke Model Generatif

   Hasil keluaran dari NLP dan NER kemudian digabungkan untuk dimasukkan ke dalam model generative IndoBART. Tujuannya agar model tidak hanya memahami konteks teks, tetapi juga mampu menghasilkan teks baru secara otomatis dengan mempertahankan informasi pentign dari entitas yang telah dikenali.

6. Analisis dan Evaluasi Hasil

   Setelah proses pelatihan model selesai, selanjutnya akan dilakukan evaluasi model dengan menggunakan metrik untuk menguji hasil. Setelah proses evaluasi sisem siap digunakan untuk pembuatan teks otomatis.

D. Teknik Pengujian Sistem

Pengujian sistem ini dilakukan untuk memastikan rancangan sistem pembuatan

teks otomatis dapat berjalan sesuai dengan kebutuhan yang telah direncanakan. Adapun teknik pengujian yang diguakan adalah sebagai berikut:

1. Pengujian Fungsional

   Pengujian ini dilakukan untuk memastikan setiap tahapan sistem, mulai dari preprocessing, ekstraksi entitas, dan generasi teks, dapat berfungsi sesuai dengan flowchart perancangan.

2. Pengujian Kinerja Model

   Evaluasi teks dilakukan dengan menggunakan beberapa metrik, yaitu Precision, Recall dan F-Score

Setelah sistem diuji dengan menggunakan data nyata berupa dokumen administrasi. Tujuan dari tahap ini adalah untuk mengevaluasi keandalan sistem dalam penggunaan nyata serta kemudahan dan efektivitas bagi pengguna.

E. Teknik Analisis Data

Analisis data dalam penelitian ini dilakukan secara kuantitatif untuk menilai kerja sistem pembuatan teks otomatis. Tahapan analisis mencakup:

1. Analisis Statistik Deskriptif

   Analisis ini dilakukan untuk memberikan gambaran umum mengenai dataset teks dokumen administrasi yang digunakan. Tahap ini mencakup jumlah dokumen, panjang rata-rata kalimat, distribusi jumlah entitas (nama, lokasi, organisasi, waktu), serta variasi kata kunci. Analisis deskriptif ini bertujuan untuk mengetahui karakteristik awal data sebelum diproses lebih lanjut.

2. Pra-pemrosesan Data

   Dataset teks yang diperoleh melalui proses pembersihan dan normalisasi, meliputi penghapusan karakter khusus, tokenisasi, lemmatisasi, parsing sintaksis, dan pembagian data menjadi data latih serta data uji. Pada tahap ini juga dilakukan anotasi manual entitas untuk kebutuhan evaluasi NER. Pra-pemrosesan bertujuan untuk memastikan bahwa data valid, konsisten, dan siap digunakan dalam pelatihan serta pengujian model.

3. Evaluasi Hasil Model

   Evaluasi dilakukan setelah sistem menghasilkan teks otomatis. Penilaian

kualitas dilakukan dengan pendekatan:

- Evaluasi menggunakan metrik Precision, Recall, dan F1-Score untuk menilai akurasi pengenalan entitas.

BAB IV
HASIL DAN PEMBAHASAN

A. Pengumpulan data

Dataset dalam penelitian ini diperoleh dari arsip surat administrasi Kelurahan Tadokkong yang disimpan dalam bentuk dokumen digital Microsoft Word (.docx). Data dokumen surat yang diperoleh adalah 185 file, dan seluruhnya merupakan file .docx. Dengan demikian, pada dataset ini tidak ditemukan file non-.docx. Selanjutnya dilakukan proses seleksi untuk memisahkan dokumen yang relevan dengan tujuan penelitian dari dokumen non-target. Dokumen yang dipertahankan adalah surat administrasi warga yang memiliki muatan informasi tekstual formal dan memuat entitas penting seperti nama, NIK, alamat, pekerjaan, serta nomor surat. Dokumen non-target yang dikeluarkan meliputi himbauan, makalah, indeks arsip, jadwal, surat edaran, dokumen kelembagaan, dan file hasil pemulihan dokumen.

Dari hasil seleksi, diperoleh 170 dokumen relevan sebagai kandidat dataset utama, sedangkan 15 dokumen dikeluarkan dari proses analisis, yang terdiri atas 12 dokumen non-target dan 3 dokumen duplikat.

Tabel. 2 Data Dokumen

Komponen	Jumlah
File .docx	185
File non-.docx	0
Dokumen relevan	170
Dokumen dibuang	15
Dokumen non-target	12
Dokumen duplikat	3
Total File	185

Berdasarkan tabel tersebut, dapat diketahui bahwa mayoritas arsip terdiri atas dokumen surat administrasi.

Tabel . 3 Data Dokumen yang dikeluarkan dari dataset

No	Nama file	Alasan
1	Himbauan Kebakaran 2023.docx	Dokumen himbauan umum
2	Himbauan Menjelang Tahun Baru 2025.docx	Dokumen himbauan umum
3	INDEKS ARSIP KEL.TADOKKONG.docx	Indeks arsip
4	JADWAL PELAJARAN.docx	Dokumen jadwal
5	MAKALAH ETIKA MEMINJAM SECARA ISLAMI.docx	Makalah
6	SK Tim Kelurahan Siaga TBC Tadokkong2025.docx	Dokumen kelembagaan
7	SURAT EDARAN 2026.docx	Surat edaran
8	SURAT PERMOHONAN KERINGANAN UKT.docx	Surat pribadi non-layanan kelurahan
9	Permohonan Perekaman KTP 2024.docx	Surat dinas administratif
10	logo pkk.docx	Bukan surat administrasi warga

B. Praprocessing Data

DAFTAR PUSTAKA

Ahmadian, H., Abidin, T. F., Riza, H., & Muchtar, K. (2024). Hybrid Models for Emotion Classification and Sentiment Analysis in Indonesian Language. *Applied Computational Intelligence and Soft Computing*, *2024*. https://doi.org/10.1155/2024/2826773

Akhtar, Z., Arshad, A., Zubair, M., Qasim, A., Ullah, F., Zamir, M. T., Ahmad, M., Sidorov, G., & Gelbukh, A. (2024). Named Entity Recognition Tools and Techniques in Custom Natural Language Processing Models. *Journal of Population Therapeutics and Clinical Pharmacology*, *31*(10), 673–684. https://doi.org/10.53555/e8b2km73

Aulia, I., Purnamawati, S., & Junianto, J. (2020). Textual interpretation generation in Indonesian language based on blood chemistry tests data using r-template based approach. *Jurnal Teknologi Dan Sistem Komputer*, *8*(1), 44–53. https://doi.org/10.14710/jtsiskom.8.1.2020.44-53

Bahari, A., & Dewi, K. E. (2024). Peringkasan Teks Otomatis Abstraktif Menggunakan Transformer Pada Teks Bahasa Indonesia. *Komputa : Jurnal Ilmiah Komputer Dan Informatika*, *13*(1), 83–91. https://doi.org/10.34010/komputa.v13i1.11197

Fardhina, A., Siregar, R. M., Ria, M., Br, W., Chlara, I., Ginting, B., Teknologi, F., Satya, U., & Bhinneka, T. (2025). *SISTEM DETEKSI BERITA HOAKS BERBASIS ALGORITMA NATURAL LANGUAGE PROCESSING (NLP) MENGGUNAKAN BERT*. *4*(1), 450–461. https://doi.org/10.70247/jumistik.v4i1.156

Fathoni, F. A. (2025). *Pemanfaatan Machine Learning dan Natural Language Processing (NLP) Pemanfaatan Machine Learning dan Natural Language Processing (NLP) dalam Deteksi dan Mitigasi Ancaman Social Engineering*. *July*.

Fredyan, R., Wiyono, I. S., Suhartono, D., Majiid, M. R. N., & Purnomo, F. (2024). Enhancing Question Generation in Bahasa Using Pretrained Language Models. *Revue d'Intelligence Artificielle*, *38*(4), 1275–1284. https://doi.org/10.18280/ria.380421

Hakim, L. (2023). *Penerapan NER pada Artikel Berita Online Tentang Kriminalitas Menggunakan IndoBERT*.

Hidayatullah, A. F., Putra, M. F. D. A., Wibowo, A. P., & Nastiti, K. R. (2023). Named Entity Recognition on Tourist Destinations Reviews in the Indonesian Language. *Jurnal Linguistik Komputasional (JLK)*, *6*(1), 30–35. https://doi.org/10.26418/jlk.v6i1.89

Husniah, F., Agustian, S., & Afrianty, I. (2022). Peringkasan Teks Otomatis Artikel Berbahasa

Indonesia Menggunakan Algoritma Textrank. *TEKNOKA National Seminar*, *7*(2502), 2022.

Islamey, J., Jonathan, V., Nurzaki, M., & Lucky, H. (2024). Comparative Analysis of Encoder-Based Pretrained Models: Investigating the Performance of BERT Variants in Indonesian Question-Answering. *2024 International Conference on Artificial Intelligence, Blockchain, Cloud Computing, and Data Analytics, ICoABCD 2024*, 309–314. https://doi.org/10.1109/ICoABCD63526.2024.10704260

Koto, F., Rahimi, A., Lau, J. H., & Baldwin, T. (2020). IndoLEM and IndoBERT: A Benchmark Dataset and Pre-trained Language Model for Indonesian NLP. *COLING 2020 - 28th International Conference on Computational Linguistics, Proceedings of the Conference*, 757–770. https://doi.org/10.18653/v1/2020.coling-main.66

Mahira Putri, Sutanto, T. E., & Inna, S. (2023). Studi Empiris Model BERT dan DistilBERT Analisis Sentimen pada Pemilihan Presiden Indonesia. *Indonesian Journal of Computer Science*, *12*(5), 2972–2980. https://doi.org/10.33022/ijcs.v12i5.3445

Muftie, F., & Haris, M. (2023). IndoBERT Based Data Augmentation for Indonesian Text Classification. *2023 International Conference on Information Technology Research and Innovation, ICITRI 2023*, 128–132. https://doi.org/10.1109/ICITRI59340.2023.10250061

Nurchim, N., Nurmalitasari, N., & Long, Z. A. (2023). Indonesian news classification application with named entity recognition approach. *Jurnal Infotel*, *15*(2), 130–134. https://doi.org/10.20895/infotel.v15i2.909

Sebastian, D., Purnomo, H. D., & Sembiring, I. (2022). BERT for Natural Language Processing in Bahasa Indonesia. *2022 2nd International Conference on Intelligent Cybernetics Technology and Applications, ICICyTA 2022*, 204–209. https://doi.org/10.1109/ICICyTA57421.2022.10038230

Sianturi, M. H. F., Ridok, A., & Santoso, E. (2023). Peringkasan Teks Otomatis menggunakan Metode Latent Semantic Analysis pada Artikel Berita Ekonomi berbahasa Indonesia. *Jurnal Pengembangan Teknologi Informasi Dan Ilmu Komputer*, *7*(5), 2589–2596.

Suarna, N., & Prihartono, W. (2024). Implementation of NLP (Natural Language Processing) in Sentiment Analysis of Telegram Users on Play Store. *Jurnal Mahasiswa Teknik Informatika*, *8*(2), 1841.

Subowo, E., Bukhori, I., & Warto. (2025). Corpus Development and NER Model for Identification of Legal Entities (Articles, Laws, and Sanctions) in Corruption Court

Decisions in Indonesia. *Transactions on Informatics and Data Science*, *2*(1), 27–39. https://doi.org/10.24090/tids.v2i1.13592

Suhartono, D., Majiid, M. R. N., & Fredyan, R. (2024). Towards automatic question generation using pre-trained model in academic field for Bahasa Indonesia. In *Education and Information Technologies* (Vol. 29, Issue 16). Springer US. https://doi.org/10.1007/s10639-024-12717-9

Theofany Aulia Anwar, M., Hadi Wijoyo, S., & Hayuhardhika Nugraha Putra, W. (2024). Implementasi Metode TextRank dan Named Entity Recognition Untuk Ekstraksi Kata Kunci Pada Media Online Berita. *Jurnal Sistem Informasi, Teknologi Informasi, Dan Edukasi Sistem Informasi*, *5*(1), 34–41. https://doi.org/10.25126/justsi.v5i1.401

Tohir, H., Merlina, N., & Haris, M. (2024). Utilizing Retrieval-Augmented Generation in Large Language Models To Enhance Indonesian Language Nlp. *JITK (Jurnal Ilmu Pengetahuan Dan Teknologi Komputer)*, *10*(2), 352–360. https://doi.org/10.33480/jitk.v10i2.5916

Yanti, R. M., Santoso, I., & Suadaa, L. H. (2021). Application of Named Entity Recognition via Twitter on SpaCy in Indonesian (Case Study : Power Failure in the Special Region of Yogyakarta). *Indonesian Journal of Information Systems*, *4*(1), 76–86. https://doi.org/10.24002/ijis.v4i1.4677